技术文档：基于大模型的多模态视觉理解与推理

> 对应提交文件：`AIC-2026-14375345-赛题结果文档/result.zip`（内部文件名 `submission.json`）赛题：全球校园人工智能算法精英大赛 · 基于大模型的多模态视觉理解与推理

1. 任务与方案概述

1.1 任务定义

赛题要求给定同一场景的**可见光（visible）、红外（infrared）、深度（depth）**三模态图像，以及一条描述目标的英文查询，输出该目标在可见光图像中的**归一化边界框** [x1, y1, x2, y2]（x1/y1 为左上角、x2/y2 为右下角，均由像素坐标除以图像宽高得到，取值范围 0~1）。

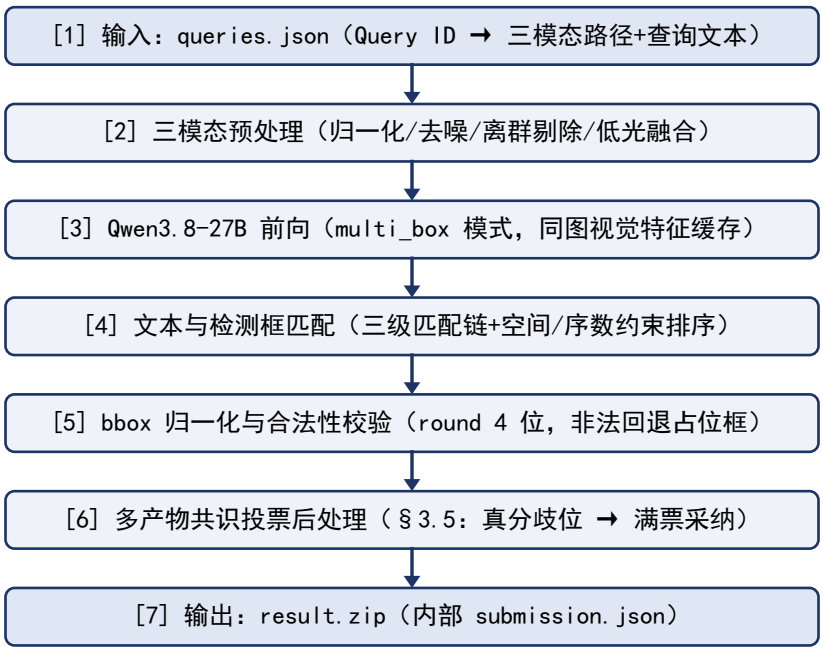
评测指标为 **ACC@0.5**：预测框与真实框的交并比 IoU ⩾ 0.5 记为该条正确，最终得分为正确条数占总查询数的比例。

1.2 方案路线

本方案采用**预训练多模态大语言模型 Qwen3.8-27B-Instruct 的零样本推理**路线。选择该路线的原因有三：

- **任务适配**：查询文本常含外观描述、空间关系、序数指代（"从右往左第三个"）等需要语义推理的成分，生成式大模型在语言-视觉对齐与常识推理上具备优势；
- **合规友好**：赛题要求仅使用开源模型，且禁止调用闭源模型在线 API——本地部署的 Qwen3.8-27B 满足要求；
- **无需训练**：赛题不提供训练集，零样本路线避免了在无监督信号下做适配带来的过拟合风险。

1.3 整体流程



其中第 1–5 步由 scripts/infer.py 端到端完成，第 6 步由 scripts/consensus_vote.py 独立完成，第 7 步为打包输出；两步之间以预测 JSON 为接口，可分别复现与校验。

1.4 赛题合规要点

- **模型**：开源模型 Qwen3.8-27B，本地部署推理，全程无商业闭源 API 调用；
- **数据**：仅使用赛事官方测试集，未使用外部数据、未对测试集做任何标注；
- **推理**：结果全部由算法推理产出，不含任何人工指定；后处理为确定性规则，可由管线逐条复算。

2. 数据集

本方案仅使用赛事官方提供的测试集进行推理，未使用任何外部训练数据（零样本推理，无训练环节）。

项目	内容
图像规模	1295 张场景图像（三模态各一份）
查询规模	5690 条查询（多查询/图）
模态	visible/infrared/depth（depth 为深度图）
输入	三模态图像路径+queries.json
输出	Query ID → {visible, infrared, depth, query, bbox}

三模态数据特性及其对方案的约束：

- **可见光**：三通道 8 位 RGB，提供外观纹理与色彩，是主要定位依据，但弱光场景下细节损失严重；
- **红外**：实质为单通道热辐射灰度图的三通道堆叠，像素值越高表示温度越高。在可见光失效的弱光场景中，红外可突显活体与热源轮廓，是主要的补充模态；
- **深度**：单通道 16 位，单位为毫米，相机可感知距离约 300~19999 mm（编码取值范围 0~19999）；数值为 0 或过小表示无效区域。深度提供目标与相机的空间距离，可用于区分"近处/远处"这类空间指代。

3. 技术方案

3.1 模型

属性	取值
模型	Qwen3.8-27B-Instruct（ModelScope Qwen/Qwen3.8-27B）
参数量	27.78B
精度	bfloat16
权重	Safetensors 18 分片，约 54GB
加载	AutoModelForImageTextToText+AutoProcessor

模型以 transformers 原生接口加载与推理，未做任何微调或参数修改。选择 27B 规模的动因在于：本赛题的困难样本集中在遮挡、同类物并存、序数指代等需要细粒度语义区分的场景，参数量更大的模型在开放词汇定位上的零样本表现更稳定。

3.2 多模态输入与预处理（src/data/）

预处理针对三模态各自的数据特性分别设计，目的是让模型接收到的输入在量纲、噪声与有效区域上保持一致：

- **可见光**：uint8 → float32 / 255.0 归一化到 [0,1]，统一量纲以避免与模型内部归一化叠加；本次提交原样输入，不做像素级融合；
- **红外**：三通道实为同一灰度辐射图的三次堆叠，先转灰度、再中值滤波去除椒盐噪声、最后复制为三通道伪 RGB，消除通道冗余并抑制传感器噪点；
- **深度**：超出编码取值范围（0~19999 毫米）的像素判定为无效区并置零，再线性归一化并保留有效区掩码（详见

§3.3.4），避免无效值被模型误读为"极近"或"极远"；

- **可选的低光融合（本次未启用）**：当可见光平均亮度低于阈值（low_light_threshold: 60）时判定为弱光场景，工程内提供两条增强路径——fuse_rgb_infrared（红外按固定权重与可见光加权，配合直方图均衡）与 gated_fusion（逐像素 Sigmoid 门控，深度无效区硬置 0）。本次提交采用下条的分图输入，故这两条路径保持关闭；赛题背景中"夜间可见光模糊时由红外突显目标热源轮廓"即指此类情形；
- **输入组织（本次采用）**：三模态以分图（split）方式送入视觉编码器（multimodal_input_mode: "split"），保持各自的空间对齐关系，不做通道拼接，以避免不同物理量纲的图像被混合编码。可见光原样输入；红外与深度分别经去噪与掩码处理后作为独立模态输入，三图按「可见光 → 红外 → 深度」固定顺序送入，提示词附「Image 1 为可见光、Image 2 为红外热像、Image 3 为深度图」的角色说明，并要求 bbox 一律给出在 Image 1（可见光）坐标系上。

3.3 推理（src/inference/、src/models/）

推理把「语义理解」与「坐标计算」分开：模型负责识别与定位，凡能用纯几何规则确定性表达的部分（序数、方位、相对参照）都交给规则层，避免让模型做它最不擅长的计数与排序。

3.3.1 生成与缓存

- **生成模式**：multi_box —— 同一张图像的多条查询一次前向生成多个检测框，相比"逐查询单框"显著减少前向次数；enable_thinking: false 关闭思维链输出以控制生成长度，max_new_tokens: 1024 为上限；
- **视觉特征缓存**：以图像内容哈希为键的有界 LRU（cache_max_entries: 4）。同图多查询场景下视觉塔仅编码一次，后续查询复用视觉特征——这是 multi_box 模式下最有效的加速手段，直接决定全量推理的可行时长；

3.3.2 候选匹配与序数层

复赛中约 **19.4%** 的查询含序数词（first/second/third … from left/right/top/bottom）。通用 VLM 能定位到**某个同类物体**，但未必是查询**指定的那一个**——让它做"从右数第三个"这类计数与排序，正是它最不擅长的部分。据此把该步拆成两半：

- **候选匹配链**：模型输出的坐标经容错解析后，由 matcher 执行三级匹配链——① 精确标签匹配 → ② 双向单词子集软匹配（容忍模型回显多/少若干修饰词）→ ③ 顺序子串匹配（容忍词序插入）；命中候选多于一个且查询含空间或序数约束时，进入下述序数选择，无约束则取置信度最高者；
- **提示词层**（qwen3_vl_parse.py 规则 1，本次提交启用）：要求模型从查询指定的方向边缘**起算**，逐个计数匹配物体，**只框第 n 个**；明确禁止"取最大/最显著目标"，并禁止把相邻物体一并框入——把"数"的负担降到最低；
- **几何层**（matcher.parse_spatial_constraint，本次提交启用）：从查询解析出 (轴, 方向, rank)，对候选框按该轴中心坐标排序后取第 rank 个。"从某端数第 k 个"由此变成一次确定性排序，结果不再依赖模型是否"数对"；
- **可选增强**（detect_select.py，模块随包提供、本次配置未启用）：把上述两步显式化为"枚举+选择"——先让模型 List EVERY <NP> 逐个给出同类实例（不做序数判断），再按 x/y 中心排序取第 k 个；closest/farthest 类改用深度图 ROI 平均深度排序，**深度不可用时宁可回退常规分支也不猜**。其约束解析额外覆盖 from left to right, the first …、<ord> lowest/highest floor、from near to far、in the middle 四类语序变体；
- **跨查询一致性**（chains.py，模块随包提供、本次配置未启用）：同图、同物体（残余实义词相同）、同轴同向的序数链，其框中心必须随序数单调——实测 181 条有效链中有 30% 违反该约束。对破序链做**排序式重指派**：同链成员为同类物体、框可互换，按位置排序后依序数重新指派即 L1-最优分配（另提供 PAVA 保序回归变体）；已单调的链完全不动，因此该操作幂等。

以上均为**零样本**手段：只调整提示词与后处理规则，不训练、不伪标注、不使用任何真值信息。本次提交的配置中，序数链一致性修正（chain_enforce: "off"）与深度先验（enable_depth_prior: false）保持关闭。

3.3.3 相对位置与参照物语义

查询中的方位词存在两种参照系，若不区分就会系统性取错：

- **以物体自身为参照**：the right side of the car 指车自身的右侧——当车面向镜头时，车的右侧落在**画面**左侧；
- **以图像为参照**：on the right of the image、rightmost in the frame 指**画面**右缘。

提示词规则 2 对二者给出显式判据，要求模型按查询措辞选择参照系；规则 3 要求"物体的某一部分"（车灯、标志、手、后视镜、轮子）只框该局部而非整物；规则 5 把颜色词当作硬约束，禁止用位置"看似正确"但颜色不符的物体顶替。

几何侧把方位词映射为 (轴, 方向)：left/top → +1、right/bottom → -1（与 detect_select.py 的 _DIR2AXIS 同口径），与序数 rank 组合后即可在候选集上做确定性选择（§3.3.2）；closest/farthest 则映射到深度轴，由深度图 ROI 平均深度排序。

3.3.4 深度与红外的辅助判别

三模态并非简单叠加，各有明确的判别职责：

- **深度 → 距离与前后相对位置**：深度图（16 位、单位毫米）经量程外离群剔除后线性归一化，并给出**有效区掩码**与**四级置信度**（high/medium/low/skip，按有效像素占比划分，见 preprocess.depth_confidence）——本题数据中深度无效区占比偏高（实测中位 25.18%），故掩码是必备而非可选。分图输入时深度以"近处暗、远处亮、无效区为黑"的伪 RGB 呈现，模型据此判断遮挡与前后关系；规则侧则可用**框内 ROI 有效像素的平均深度**对候选排序，closest/nearest/farthest/furthest 远近类查询即按此取框（matcher.match_query_with_depth，本次配置关闭；detect_select.select_box 为同思路的显式版本）。深度缺失或置信度不足时**宁可回退常规分支也不猜**。
- **红外 → 热辐射与弱光补充**：红外像素值越高表示温度越高，可在可见光失效（夜间、逆光、遮挡）时突显活体与热源轮廓。工程内先转灰度并中值滤波去噪，再以「红外热像」角色作为独立模态输入，使模型在可见光证据不足时有**第二证据源**；低光时亦可用于加权增强可见光（§3.2 的可选路径）。
- **可见光 → 外观与纹理**：作为主模态承担类别、颜色、部件等细粒度判据（对应提示词规则 3 与规则 5），最终 bbox 也定义在可见光坐标系上。

三者共同支撑"相对于某物"的方位与序数判断：判断某人相对某车的左右与前后时，可见光负责定位人与车并确认为同类目标，红外用于确认活体、避免与车体阴影混淆，深度用于分离人与车的前后关系，再由 §3.3.3 的参照系规则决定左右取向。**温度本身不做数值估计**，仅以红外强度间接反映。

3.4 后处理与提交格式（src/postprocess/、make_sub.py）

- **坐标规范**：bbox 归一化到 [0,1]，坐标 round 至 4 位小数；
- **异常回退**：非法或缺失的预测（反向坐标、越界、NaN、空框）回退到占位框 [0.49, 0.49, 0.51, 0.51]；
- **字段回显**：每查询条目附原始三模态路径与查询文本，除 bbox 外的四个字段逐字回显，不改动任何字符；
- **打包**：形成 submission.json 并 zip 压缩（内部文件名 submission.json）供平台提交。

3.5 多产物共识投票后处理（scripts/consensus_vote.py）

本节为本次方案的核心增量。

3.5.1 问题

零样本生成式定位的单次解码输出（下称**主件**）存在两类不稳定性：

1. **解码波动**：bfloat16 浮点与采样噪声使同一配置的两次全量推理在 11% 的条目上给出不同框；
2. **系统性偏差**：在部分困难位（目标遮挡、同类物并存、序数指代歧义）上，主件与其它解码结果的判断不一致，而单一模型无法自证孰是孰非。

换言之，主件在"与其它解码结果不一致的位置"上并无额外可信度。这正是后处理要处理的靶区。

3.5.2 方法

引入**多产物共识投票**，把"该采信哪个框"转化为"哪个框获得更一致的第三方支持"。

记主件框 b_main、参照件框 b_ref（另一次独立解码结果）、投票池 P（|P| = 32 套）。对每个查询位：

第一步：候选面筛选。 仅当 IoU(b_main, b_ref) < 0.5（**真分歧位**，即两套结果指向不同区域）时进入投票判定；IoU ⩾ 0.5 的同侧位两套结果本就一致，改动不构成有效修正，直接跳过。该步骤将判定范围从 5690 条收缩到真分歧位，避免在无分歧处做无意义扰动。

第二步：逐成员表态。 对池中每个成员 p（属于池 P），比较 IoU(b_p, b_main) 与 IoU(b_p, b_ref)：

- 若前者更大 → 记主件票 sa += 1；
- 若后者更大 → 记参照件票 sq += 1；
- 若两者相等 → **弃权**，不计票。

第三步：判决。 当且仅当 sa == 0 且 sq == |P|（主件零票、参照件满票）时，采纳参照件框；其余候选位一律保持主件框。

3.5.3 判据设计说明

- **以 IoU 作为表态依据**：IoU 是与真值无关的纯几何量，不含任何可调参数、学习权重或经验系数。在无真值的评测环境下，引入任何需要拟合的参数都会带来无法验证的过拟合风险；
- **阈值取满票而非多数票**：满票要求全体成员一致。只要出现任何一张异见票，即判定该分歧存在非单侧成因，保持主件不动。该设计使改动面收缩到一致性最高的一档——即以"牺牲改动数量"换取"改动质量"。这一取向在无真值可校验的场景下是必要的保守选择；
- **弃权即不计票**：当成员框与主件、参照件的 IoU 相等（典型情形是三者互不相交、IoU 均为 0）时不予表态。弃权会降低 sq，使该位无法达成满票——即"证据不足则不动"；
- **计算复杂度**：O(候选位数 × |P|)，本例约 3 万次 IoU 计算，秒级完成，不构成运行瓶颈。

3.5.4 与赛题条款的对应

赛题 §十（四）「推理预测与结果优化」明确鼓励："可采用多模型集成推理（如不同预训练模型预测结果加权平均）提升定位准确性"。

本方法属于该范畴的**离散表决**变体：不做加权平均（以免引入权重这一在无真值下无法校验的自由参数），而以"全体一致"作为唯一的采纳条件。投票池由同一推理工程的多组独立运行输出汇总而成，随包分发以保证离线可复现。

3.5.5 确定性保证

管线固定 zip 内部时间戳，投票规则不含任何随机性，因此**同输入必得同 SHA256**，结果可由第三方逐条复算核对。

3.6 提交件校验与结果

产出 result.zip（内部 submission.json，共 5690 条）后执行四项硬约束校验，全部通过：

校验项	判据	结果
条数	与测试集一致（5690 条）	通过
键集	与 queries.json 完全一致	通过
字段回显	visible/infrared/depth/query 四字段逐字一致	通过
bbox 合法性	归一化、x1 < x2、y1 < y2 且落在 [0,1]	通过

平台评测指标 **ACC@0.5 = 0.8116**。

4. 运行配置（configs/server_32b.yaml 关键项）

```
data:
  root: "/root/autodl-tmp/work"            # 测试集根目录（Images/、queries.json）
model:
```

```
  type: "qwen3_vl"
  name_or_path: "/root/autodl-tmp/models/Qwen3.8-27B"
  device: "cuda:0"
  use_half_precision: true
  box_threshold: 0.20
  text_threshold: 0.15
inference:
  max_queries_per_prompt: 20
  enable_multimodal_fusion: true
  low_light_threshold: 60
  fusion_mode: "low_light"
  multimodal_input_mode: "split"
  enable_depth_prior: false
  chain_enforce: "off"
  diag_dump: false
qwen:
  output_mode: "multi_box"
  max_new_tokens: 1024
  enable_thinking: false
  feature_cache: true
  cache_max_entries: 4
postprocess:
  fallback_bbox: [0.49, 0.49, 0.51, 0.51]
```

5. 环境与复现

依赖	版本/要求
GPU	显存 ≥ 60GB（实测 RTX PRO 6000 Blackwell 96GB）
系统	Linux（Ubuntu），磁盘 ≥ 100GB
Python	3.12
CUDA	12.4

关键依赖：torch≥2.6、transformers≥5.18.0、accelerate、opencv-python、Pillow、numpy、PyYAML、tqdm（详见 requirements.txt）。

模型权重与数据集未随包分发，获取方式见 §6。

复现步骤（完整版见 code27b/README.md）：

```
pip install -r requirements.txt
# 下载模型：modelscope snapshot_download('Qwen/Qwen3.8-27B', cache_dir='./models')
# 放置测试集：data.root 下 Images/visible|infrared|depth 与 queries.json
python scripts/infer.py --config configs/server_32b.yaml
python scripts/consensus_vote.py                    # 共识投票后处理，产出 result.zip
```

6. 大文件与外部链接

本方案的作品文档（技术方案 PDF、代码与数据包）及其链接**不包含模型权重、数据集、运行环境等大文件**：随包材料全部为代码、配置与说明，合计约 7.4 MB。大文件按下方**独立链接**获取：

大文件	体积	获取方式（独立链接）
模型权重 Qwen3.8-27B-Instruct	约 54 GB	ModelScope 官方地址 Qwen/Qwen3.8-27B；另附 download_model.py 与 18 分片 SHA256 校验
赛题测试数据	—	由赛事方提供，未随包分发
运行环境	—	依赖清单见 code27b/requirements.txt（未提供镜像）

权重下载与逐分片校验：

```
pip install modelscope
python download_model.py                # 下载到 ./models/Qwen3.8-27B
python download_model.py --verify       # 对照 18 分片 SHA256
```

分片哈希清单见 AIC-2026-14375345-模型文件/model_sha256.txt；测试数据按configs/server_32b.yaml 的 data.root 放置，不入包。