技术文档：Qwen3.8-27B 多模态视觉定位推理（2026-10-04 版本）

对应提交文件：

预测结果文件/submission.json

、

预测结果文件/submit_27b.zip
对应推理日志：

D:\GroundingDINO\v27b\run_27b.log

（2026-10-04 17:52:43 - 23:25:08）

1. 任务与方案概述

本方案面向「基于大模型的多模态视觉理解与推理」赛题：给定同一场景的可见光（visible）、红外（infrared）、深度（depth）三模态图像与一条自然语言查询（如 "A squatting person"），模型需输出查询目标在图像中的归一化边界框（bbox） [x1, y1, x2, y2]（取值范围 0~1）。

方案采用预训练多模态大语言模型 Qwen3.8-27B-Instruct 零样本推理路线：

* 不训练、不微调，直接利用大模型已有的视觉 - 语言对齐能力完成开放词汇目标定位；

* 三模态图像以分图（split）方式组织为多模态输入，配合数据预处理的多模态协同策略提升低光 / 红外场景鲁棒性；

* 模型以 multi_box 模式一次生成多个候选框，经解析与后处理输出每查询一个归一化 bbox。

2. 数据集

项目	内容
图像规模	1295 张场景图像（三模态各 1295 张对应文件）
查询规模	5690 条查询（多查询 / 图）
模态	visible /infrared/depth（三通道，depth 为深度图）
输入格式	\`Images/visible
输出格式	Query ID -> {visible, infrared, depth, query, bbox}

3. 技术方案

3.1 模型

属性	取值
模型	Qwen3.8-27B-Instruct（ModelScope：Qwen/Qwen3.8-27B）

参数量	27.78B
精度	bfloat16（use_half_precision: true）

权重规模	Safetensors 18 分片，约 54GB
加载方式	AutoModelForImageTextToText + AutoProcessor（transformers≥5.18.0）

3.2 多模态输入与预处理（src/data/）

* RGB 归一化：uint8 → float32 / 255.0；

* 红外去噪：红外三通道视觉特征高度一致，转灰度后中值滤波去除椒盐噪声，再恢复三通道；

* 深度离群剔除：深度值超出有效范围（0 ~ 19999 毫米）视为无效并剔除；

* 低光多模态协同：可见光亮度低于阈值（low_light_threshold: 60）时，以门控融合（fusion_gate_scale: 30.0）引入红外 / 深度特征增强可见光（fusion_ir_weight: 1.0、fusion_depth_weight: 1.0）；

* 输入组织：multimodal_input_mode: "split"——可见光 / 红外 / 深度分图送入视觉编码器，保持三模态空间对齐。

3.3 推理（src/inference/、src/models/qwen3_vl.py）

* 模式：multi_box（单图一次生成多个检测框），enable_thinking: false（关闭思维链输出以提速），max_new_tokens: 1024；

* 视觉特征缓存：feature_cache: true、cache_max_entries: 4——同一图像的多条查询共享视觉特征，显著减少重复前向计算；

* 文本 - 检测框匹配：解析模型输出坐标 → matcher 做文本标签与检测框匹配 → bbox 归一化；

* 序数链约束 chain_enforce: "off"（跨查询一致性约束默认关闭）、深度先验 enable_depth_prior: false（本次提交未启用）。

3.4 后处理与提交格式（src/postprocess/、make_sub.py）

* bbox 归一化到 [0,1]，坐标 round 至 4 位小数；

* 非法 / 缺失输出回退到占位框 [0.49, 0.49, 0.51, 0.51]；

* 每查询条目附原始三模态路径与查询文本，形成 submission.json；zip 压缩（内部文件名 submission.json）供平台提交。

4. 运行配置（configs/server_32b.yaml 关键项）

```
data:
  root: "/root/autodl-tmp/work"            # 测试集根目录（Images/ + queries.json）
model:
  type: "qwen3_vl"
  name_or_path: "/root/autodl-tmp/models/Qwen3.8-27B"
  device: "cuda:0"
  use_half_precision: true
  box_threshold: 0.20
  text_threshold: 0.15
inference:
  max_queries_per_prompt: 20
  enable_multimodal_fusion: true
  low_light_threshold: 60
  fusion_mode: "low_light"
  multimodal_input_mode: "split"
```

```
  enable_depth_prior: false
  chain_enforce: "off"
  diag_dump: false
qwen:
  output_mode: "multi_box"
  max_new_tokens: 1024
  enable_thinking: false
  feature_cache: true
  cache_max_entries: 4
postprocess:
  fallback_bbox: [0.49, 0.49, 0.51, 0.51]
```

5. 运行结果（2026-10-04 实跑记录）

阶段	时间	说明
启动	17:52:43	载入 1295 张图像 / 5690 条查询
模型加载	17:53:00	bfloat16 + multi_box + 视觉缓存加载完成
首批进度	17:58:16	20/1295（模型预热后进入稳态）
末批进度	23:21:49	1280/1295
完成	23:25:08	1295/1295；共 5690 条预测，用时 19944.9 秒（约 5.54 小时）
结果落盘	23:25:08	outputs/predictions_27b.json（645,834 字节）
提交生成	23:28	本地 make_sub.py → submission.json（1,751,553 字节）+ submit_27b.zip

质量校验：

* 5690 / 5690 条预测齐全，无缺漏；
* 全部 bbox 为合法归一化坐标 [x1,y1,x2,y2]（0~1），无越界；
* 与后续 2026-10-05 独立复跑版本逐条对比：5039/5690 条一致、651 条存在浮点 / 采样级微小差异，两版均通过完整性与合法性校验。

6. 环境与复现

依赖	版本 / 要求
GPU	显存 ≥ 60GB（实测 RTX PRO 6000 Blackwell 96GB）
系统	Linux（Ubuntu），磁盘 ≥ 100GB
Python	3.12（conda 环境 vl）
CUDA	12.4
关键依赖	torch≥2.6、transformers≥5.18.0、accelerate、opencv-python、Pillow、numpy、PyYAML、tqdm 等（详见 requirements.txt）

复现步骤（完整版见 README.md 五、快速开始）：

```
pip install -r 模型文件与运行环境/requirements.txt
# 下载模型：modelscope snapshot_download('Qwen/Qwen3.8-27B', cache_dir='./models')
# 放置测试集：data.root 下 Images/visible|infrared|depth + queries.json
cd 算法代码
python scripts/infer.py --config configs/server_32b.yaml --output outputs/predictions.json
python scripts/export_submission.py --config configs/server_32b.yaml --predictions outputs/predictions.json
```

7. 版本说明

本技术文档对应2026-10-04 运行的基准提交版本（提交包 v27b_submit）。另有一份 2026-10-05 凌晨独立重新推理的版本（5690 条，与基准版 651 条预测不同），已单独保存于 D:\GroundingDINO\早上跑的27B版本\，两者代码、配置、数据一致，差异源于模型解码的浮点 / 采样波动。