技术方案：基于大模型的多模态视觉理解与推理

> 参赛团队编号 **AIC-2026-14375345** ｜ 团队名称 **熬夜炼丹师** ｜ 队长 沈嘉宝对应结果件 `AIC-2026-14375345-赛题结果文档/result_semi_q38_nonord.zip`（内部 `result_semi_q38_nonord.json`，5690 条） ｜ 线上 **ACC@0.5 = 0.7963**

1 任务与方案概述

1.1 任务定义

给定同一场景的**可见光（visible）/ 红外（infrared）/ 深度（depth）**三模态图像，以及一条描述目标的英文查询，输出该目标在可见光图像中的**归一化边界框** [x1, y1, x2, y2]（x1/y1 为左上角、x2/y2 为右下角，均由像素坐标除以图像对应的宽 / 高得到，取值范围 0~1）。

评测指标为 **ACC@0.5**：预测框与真实框的交并比 IoU ≥ 0.5 记为该条正确，最终得分为正确条数占总查询数的比例。复赛规模为 **5690 条查询 / 1295 张图**。

1.2 方案一句话

不做端到端训练：以开源多模态大模型承担**感知（直接定位）**，以**确定性规则**承担**推理（序数指代）**，以**带断言的装配器**承担**出件**。

具体地：以 Qwen3-VL 系列（8B / 32B-AWQ / 32B-bf16）与跨代模型 Qwen3.8-27B 对**非序数 4587 条**做直接定位；对**序数 1103 条**启用"查询文本程序化推算 + Set-of-Mark 选号"四层叠加；每一条新证据都只在**同机制**前提下替换上一层的框，改动范围经硬断言隔离；出件前经**六桶互斥装配器**与**硬约束校验器**把关。

1.3 合规要点

- **模型**：全部为开源模型（Qwen3-VL 系列、Qwen3.8-27B、LocateAnything-3B），本地/私有云部署，**全程未调用任何闭源在线推理 API**；
- **数据**：仅使用赛事官方提供的测试集推理，**未使用外部数据、未对测试集做任何标注**；
- **推理**：结果全部由算法自主推理产出；后处理为**确定性规则**，可由管线逐条复算。

2 数据集

2.1 规模与模态

项目	内容
图像规模	1295 张场景图像（三模态各 1295 张，缺失 0、损坏 0）
查询规模	5690 条查询（多查询 / 图）
查询分层	序数类 1103 条（19.4%，如"从右数第二个"） + 非序数 4587 条
输出格式	Query ID → {visible, infrared, depth, query, bbox}

三模态特性与其对方案的约束：

- **可见光**：三通道 8 位 RGB，提供外观纹理与色彩，是主要定位依据，但弱光场景细节损失严重；
- **红外**：实质为单通道热辐射灰度图的三通道堆叠，像素值越高表示温度越高；在可见光失效的弱光场景中可突显活体与热源轮廓，是主要补充模态；
- **深度**：单通道 16 位，单位毫米，相机可感知距离约 300~19999 mm；数值为 0 或过小表示无效区域。深度提供目标与相机的空间距离，可用于区分"近处 / 远处"这类空间指代。

2.2 数据格式发现（赛题文档未记载）

实测复赛数据集存在**两个格式不同的子群**，赛题文档只描述了其中之一：

子群	被引用 1295 张中	分辨率	深度存储	红外
.png 组	1198	1920×1080	I;16 单通道 uint16、单位毫米、实测 0–19999	PNG，三通道近似相同
.jpg 组	97（7.5%）	640×360	RGB 三通道且逐像素相同 → 实为 8 位灰度；JPEG 有损、原始 16 位量程不可还原	JPEG，三通道完全相同

- 两个子群**内部**三模态同尺寸 → **跨模态对齐性不受影响**；
- **工程陷阱**：把 3 维数组直接交给 Image.fromarray(arr, mode="L") 会抛 ValueError: Too many dimensions: 3 > 2，**使那 97 张（7.5%）整批失败**；
- **处置**：对 .jpg 组**直通原值、不按未知比例缩放**——赛题语义只需"越亮越远"的**单调性**，8 位原值已满足；按未知比例换算成毫米等于凭空造信息。零回归验证：.png 组新实现与旧规则输出**逐位相同**。

3 技术路线

3.1 总览



3.2 主模型推理（分层 + 单变量替换）

非序数层的每一级都是"在上一级的件之上做**单变量替换**"：提示词、解码（temperature=0 贪心）、并发（CONC=8）与上一级**逐字相同**，只换模型或精度。这样得分差才能干净归因。

级	模型	被替换的那一层	改动面 → 净翻转	净成功率
L3	Qwen3-VL-32B-Instruct-AWQ	8B 直接框	467 → +82	17.6%
L5	Qwen3-VL-32B-Instruct（bf16）	32B-AWQ 直接框（同族精度修复）	111 → +11	9.9%
L6	Qwen3.8-27B（跨代换模型）	32B 直接框	519 → +101	19.4%

L6 即本交付件的来源：提示词 / 解码 / 并发与 L5 逐字一致，仅把非序数层换成 Qwen3.8-27B 的输出，经装配器替换 **519** 处，线上得分由 0.7786 升至 **0.7963**（Δ = +101 条 = +0.0177，零假设 σ≈11.4 → **8.8σ**）。

起服要点（实测踩坑，已固化在 code/remote_shell/_get_serve_q38.sh）：

- disable-custom-all-reduce：cu130 + A100(cc8.0) + 驱动 580 组合下 custom all-reduce 内核在 CUDA graph 捕获阶段崩溃，退回 NCCL 即可；**不影响提示词 / 解码 / 并发**；
- limit-mm-per-prompt '{"image":1,"video":0}'：否则编码器按"最大尺寸视频"探测，一次性分配 5.77 GiB 而 OOM；
- PYTORCH_CUDA_ALLOC_CONF=expandable_segments:True：缓解显存碎片。

3.3 序数层确定性规则（四层叠加，各层改动集互不相交）

序数层是全项目最弱层（基线准确率 61.2%），改用**查询文本程序化推算**替代模型猜测：

层	含义	改动面 → 净翻转
det	水平轴文本推算（从查询里的序数词推"第 k 个"该在哪）	136 → +53
selfsort	候选自排序（枚举候选按位置重排后再取第 k 个）	41 → +9
qfb	回退点改用直接框（推算失败时不再用 SoM 选号）	47 → +3
yaxis	垂直轴序数（上下方向的"第 k 个"）	10 → +3
trunc	枚举截断组修复（枚举召回不足者换提示词重跑并合并）	52 → +11

五层之和 53+9+3+3+11 = **+79 条**，与线下序数层 596 → 675 的实测逐条吻合。

序数层还做过一次**同机制替换**（B′，L4）：判据是 IoU(基线框, 8B 直接框) ⩾ 0.999（→ 该条的当前框确实来自一个 direct 定位器），筛出 **343 条**；替换 87 处 → 净 **+14**（**16.1%**）。

3.4 装配器（六桶互斥 + 总和断言）

把"承诺"变成机器可检查的东西——每个非序数条目严格落入且仅落入一桶：

桶	判据	处置
1	模型输出无框（[]）	保留基线（留空必错，基线框至少还有猜中的机会）
2	框退化 / 逆序	保留基线
3	面积 > 0.35	保留基线（视为"合并了多个目标"的宽框）
4	面积 < 1e-5	保留基线
5	与基线一致（IoU ⩾ 0.5）	不动
6	★ 改动	采纳新框

断言：**六桶之和 == 4587**，否则直接失败、不出件。本交付件的实测桶分布为 4117 / 9 / 157 / 304（即 L7 路线的分桶；L6 交付件的六桶为 329 / – / 100 / – / 3639 / 519，合计 4587 是）。

3.5 后处理与提交格式

- bbox 归一化到 [0,1]，坐标 round 至 4 位小数；非法 / 缺失输出回退到占位框 [0.49, 0.49, 0.51, 0.51]；
- 每查询条目**四字段（visible / infrared / depth / query）逐条原样回显**，仅 bbox 为预测值；
- 结果压为 zip 提交（zip 内 JSON 名 == zip 基名）。

4 关键方法与验证手段

赛题**不提供 test.json（无任何真值）**，故本项目以四条纪律把"看不见的准确率"变成可判定的读数：

4.1 预登记（判据写在跑之前）

作用域、闸门、事前预期与止损线，全部**先写进预登记文件**（_prereg_*.md）再跑，**禁止事后调阈值**。

4.2 单变量隔离（硬断言，而非"构造上应该不动"）

每件只改一层，其余层**逐位不动**，并由脚本 assert 验证（例如只改非序数时，断言序数层 1103 条逐位相同）。这样得分差才能干净归因。

4.3 归零法（zeroing measurement）

交一件把**某个子集**的框换成**必然错的角落小框**（面积 1e-4）的"测量件"，其余子集保留真框；平台按**历史最高分**记录（测量件不拉低成绩），返回的得分**直接读出**其余子集的真实正确条数。诱饵框必须**极小且贴角**——不能用整幅框。

读数口径是**恒等式**：

```
提交分 = (非序数正确条数 + 序数正确条数) / 5690
Δ得分 × 5690 = 净翻转条数          1 条 = 0.000176
```

4.4 闸门先于全量

20 条冒烟不过就不烧全量：**G2**（机检，bbox 可解析 ≥ 16 / 20）+ **G3**（人眼，框是否落在查询描述的目标附近，三档判据**事前**写定）。

5 运行配置与环境

5.1 三段式运行

段	内容	硬件
A 离线段	数据预处理、序数核心词抽取、序数四层规则、枚举合并、装配、读数、硬约束校验	纯 CPU，无需 GPU
B 推理段（8B / 32B-AWQ）	Qwen3-VL 直接定位（Phase A）+ 序数 SoM（Phase B）	GPU ≥ 40 GB
B2 推理段（交付件 0.7963）	Qwen3.8-27B 直接定位（仅非序数）→ 装配替换	2×40 GB（权重 55.6 GB，TP=2）

5.2 实测环境（完整记录见 env_record.txt）

项	值
GPU	NVIDIA A100-SXM4-40GB（cc 8.0，40960 MiB）×2，卡间 NVLink
驱动 / CUDA	580.126.09 / driver CUDA 13.0
系统 / Python	Ubuntu 22.04.5 LTS / Python 3.10.12
推理栈（8B / 32B-AWQ 阶段）	vLLM 0.11.0、transformers 4.57.6、torch 2.8.0（cu128）
推理栈（交付件 0.7963 阶段）	独立 venv：vLLM 0.23.0、transformers 4.57.6、torch 2.11.0+cu130

硬性版本门槛：transformers 必须 < 5.0（5.x 移除 Qwen2Tokenizer.all_special_tokens_extended，启动即抛 AttributeError）；交付件级模型需 vLLM ≥ 0.22.1（Qwen3_5ForConditionalGeneration 自该版本起登记在 registry）。

5.3 关键判据与参数

常量 / 判据	值	位置
MAX_AREA	0.35	code/_fuse_qwen.py
MIN_AREA	1e-5	同上
IOU_KEEP	0.5	同上
温度 / 并发	0.0（贪心）/ QWEN_CONC=8	主管线
提示词	逐字固定（非序数直接定位 / 序数枚举 / 序数选号三套）	code/_fuse_qwen.py
B′ 作用域判据	IoU(基线框, 8B 直接框) ≥ 0.999 → 343 条	code/_assembly_ord_prime.py

6 实验结果与性能分析

6.1 成绩沿革（线上 ACC@0.5）

版本	得分	机制	改动面 → 净翻转
result_final_semi	0.7459	8B 全量 + 补框链	—
result_semi_ord_det	0.7552	+ 序数层水平轴文本推算	136 → +53
result_semi_ord_det_ss	0.7568	+ 候选自排序	41 → +9
result_semi_ord_det_ss_qfb	0.7573	+ 回退点改用直接框	47 → +3
result_semi_ord_det_ss_y_qfb	0.7578	+ 垂直序数轴	10 → +3
result_semi_enum_trunc	0.7598	+ 枚举截断组修复	52 → +11
result_semi_n32_ordbase	0.7742	32B-AWQ 重跑 4587 条非序数	467 → +82
result_semi_n32_orddirect	0.7766	序数层同机制替换（B′）	87 → +14
result_semi_n32bf16_nonord	0.7786	同族精度修复（32B bf16 重跑非序数）	111 → +11
result_semi_q38_nonord	0.7963	跨代换模型（Qwen3.8-27B 重跑非序数）	519 → +101

6.2 分层读数（归零法实测，不靠推测）

项	实测值
8B 基线非序数准确率	79.5%（错 940 条，占全部错题 69%）
8B 基线序数准确率	61.2%（错 428 条）
32B 重跑后非序数桶正确数	3730（原 3648，净 +82）
跨代换模型（Qwen3.8-27B）净翻转	+101 条（519 改动 → 19.4%，8.8σ）
交付件（0.7963）读数	非序数 3842 + 序数 689 = 4531
同机制边际成功率（四次独立测量）	17.6% / 16.1% / 9.9% / 19.4%（改动面 467 / 87 / 111 / 519）

6.3 如实留档的被否路线

GroundingDINO 三模态 **0.4378**（整批换模型完全失效）；8B 提示合并 0.7541（-24.8%）；GD 候选池 0.7566（-18.6%）；深度序数轴 0.7592（-23.1%）；序数层 32B SoM 0.7729（净 -7，约 6σ）；同模型三模态输入 0.7759（净 -4）；VLX-Seek 替换非序数 0.7492（净 -156，跨机制）；H 路线（枚举 + 几何选择）0.7786 = Δ0（作用域 94 条、面积守卫后实改 12 条 → **分辨力不足**，非"证明无效"）；L7a 异质模型 72B-AWQ 只补 q38 未采纳的 429 位 0.791（净 -30，-16.4%）。

6.4 距 0.8 的量（已量化）

> 缺口 = 0.8 − 0.7963 = 0.0037 → 21 条
> 所需改动面 = 21 ÷ 19.4% ≈ 109 条 → 需再引入一个"与当前层足够不同"的定位模型

序数侧**已无同机制余量**（SoM 层止损触发、同机制替换作用域 343 条已用尽、三模态同模型输入实测为负）；离线可做的确定性规则杠杆已穷尽。

7 创新点

1. **分层解耦 + 同机制替换的量化判据（本项目最有分量的产出）**：把"能否把一个模型的先验迁移到另一层"变成可判定条件——

杠杆	被替换的那一层	是否同机制	改动面	实测净成功率
非序数 32B 重跑	8B 直接框	是	467	+17.6%
序数层 B′	8B 直接框	是	87	+16.1%
AWQ → bf16 精度修复	32B-AWQ 直接框	是	111	+9.9%
跨代换模型 Qwen3.8-27B	32B 直接框	是	519	+19.4%
同模型三模态输入	32B 直接框	是（但重掷）	128	-3.1%
序数层 SoM	8B 直接框	否 跨机制	66	-10.6%
VLX-Seek 替换非序数	32B 直接框	否 跨机制	846	-18.4%

判据：① **同机制是必要条件**——跨机制在本项目 **5/5 全负**；② **"模型真的更强"不是必要条件**——Qwen3.8-27B 参数更小、跨代、官方无接地指标，实测却是四次同机制测量中最高的一次（+19.4%，8.8σ）；③ 真正起作用的是「**框层性质相同 + 新模型的框与原层足够不同**」，差异本身就是收益来源。

2. **把"没有真值"变成可判定读数**：预登记 + 单变量隔离件（硬断言）+ 归零法测量 + 先于全量的 G2/G3 闸门，四条纪律共同构成一套在无真值条件下仍可复算、可审计的实验方法。

3. **确定性规则承担推理**：序数指代交给"查询文本程序化推算 + 候选自排序 + 轴上投影"四层规则（净 +79 条），而非交给模型猜测——可解释、可复算、无随机性。
4. **工程鲁棒性**：识别并处置了数据集"两个格式子群"（.jpg 组深度实为 8 位灰度、且不可按未知比例还原）这一赛题文档未记载的陷阱，避免了 7.5% 条目整批失败。

8 不足之处（如实陈述）

1. **仍未达 0.8**：当前最高 **0.7963**，距 0.8 差 **21 条**（按实测 19.4% → 需约 109 条改动面）。序数侧上限被**作用域**锁死：序数层现存错题中约 760 条的来源是 SoM / det 推算 → 替换它们属**跨机制**（本项目 5/5 全负），唯一有正先验的机制够不着。继续提升需再引入一个"与当前层足够不同"的定位模型。**★ 这一条同时是本次最主要的不足**：事前把"官方有没有接地指标"当成"模型是否更强"的**代理**，据此对跨代换模型给出"不给正数"的判断，实测却是全部干预中最高的一次。代理失效、判断偏保守，是方法学上的实质失误。
2. **"可迁移范围"被后续实测进一步收窄**：追加一次同机制替换（异质模型 72B-AWQ 只补"最新模型未采纳的 429 位"）得到 **-16.4%**。→ 机制规律应收窄为：**只有"框源本身是 VLM 直接输出"的位置可迁移；对"补框链工程化填充"做替换属跨机制、为负**。"补漏通道"在结构上是空的。
3. **三模态未被有效利用**：赛题规定的算法输入是三模态，而本方案主体管线**只使用可见光**。实验证明给同一模型多喂红外与深度**不产生增量**（改动率 0.077 远小于 所需 0.465，且改动条目与基线 IoU 中位数为 0 → 重掷）。**跨模态融合是尚未突破的方向。**
4. **无真值**：全部结论依赖线上提交的单一标量反馈，无法做细粒度错误分析；归零法只能测到子集粒度。
5. **推理成本**：三图输入吞吐约 0.33 条/秒，为单图（2.34 条/秒）的 1/7，使"多模态输入"路线的验证成本显著升高。

9 复现说明

- **离线段 是 可逐字节重建**：预处理、规则层、装配、校验均确定性（核心词表可逐条重建；加轴后初版归档件 9555 条 bbox 零差异）。
- **推理段 否 不保证逐字节重建**：GPU 推理用 bfloat16 + device_map / 算子调度，浮点归约顺序随硬件、驱动、库版本变化。故本包记录**实测环境**（env_record.txt）而非断言可无限复现。
- **复现判定标准**：分数同量级（与 0.7963 差 **±0.005 以内**） + 各级"改动面 → 净翻转"的净成功率落在 **10% ~ 19%** 区间。
- 完整流程见 AIC-2026-14375345-代码与数据/复现流程.md（两条复现路径、全链 6 级逐级命令、判据与参数总表、读数口径、验收清单、已知坑速查）。